

Inteligencia artificial avanzada para la ciencia de datos

Alejandro Adrián García Martínez

Escuela de ingeniería y Ciencias

30 de septiembre del 2026

Abstracto— Este documento se enfoca en la implementación manual de un algoritmo de regresión logística utilizando una gradiente descendiente sin la asistencia de bibliotecas externas. El objetivo es desarrollar un modelo capaz de predecir con precisión si un alumno es un caso de depresión en base a distintos parámetros en su vida diaria. Se realizó un Análisis Exploratorio de Datos (EDA) para entender y limpiar los datos y permitir que el modelo los pueda interpretar de forma correcta

I. INTRODUCCIÓN

La inteligencia artificial ha evolucionado a pasos agigantados en los últimos años, pasando a volverse una herramienta de uso diario por millones de personas alrededor del mundo. Originalmente se utilizaba para crear sistemas que pudieran realizar tareas que requerían de la intervención humana, hoy en día esta se ha diversificado en distintos campos de investigación en diferentes áreas del conocimiento, uno de ellos el conocido como “Machine Learning”.

Este tipo de inteligencia artificial es capaz de aprender de los datos y mejorar su rendimiento sin tener una tarea en concreto dándole flexibilidad para poder ser utilizada en un sinnúmero de proyectos. Esta busca patrones para poder tomar decisiones y se clasifica en 3 categorías: aprendizaje supervisado, no supervisado y por esfuerzo. El modelo presentado en este documento es de tipo “Aprendizaje Supervisado” en el que se entrena un modelo con un conjunto de datos y se sabe la respuesta correcta, el modelo intenta predecir la respuesta y se compara la predicción con la real, finalmente se ajustan los parámetros del modelo para acercarse a acertar con mayor frecuencia.

II. CONTEXTO DEL PROBLEMA

A. Origen

Los datos por utilizar en este documento son recopilados de la página “Kaggle”. Estos datos recopilan las respuestas de distintos jóvenes de diferentes ciudades y contestan preguntas relacionadas a sus hábitos y esfuerzo en los estudios o trabajo.

Algunos de estos jóvenes sufren de depresión un trastorno mental que afecta la salud emocional y mental del individuo que lo sufre, algunos de los síntomas conocidos son sentimientos de tristeza, fatiga, cambios en el sueño, alteraciones en el apetito, entre otros. De no ser tratado de forma correcta puede llevar al individuo a la muerte.

El objetivo de estos datos es poder entrenar un modelo de “Machine Learning” que al conocer la respuesta a ciertos hábitos de un individuo pueda predecir si la persona sufre de depresión.

B. Base de datos

Los datos consisten en 27,901 instancias repartidas en 18 columnas o “features”. Estas columnas representan la información de la siguiente forma:

Id	Identificador único	Identificador único
Gender	Genero del individuo	Male Female
Age	Edad del individuo	Int64
City	Ciudad donde reside	Str
Profession	A que se dedican	Str
Academic Pressure	Cuanta presión sienten por parte de la escuela	0 a 5 0: Poco o nada 5: Mucho
Work Pressure	Presión por parte del trabajo	0 a 5 0: Poco o nada 5: Mucho
CGPA	Promedio académico	Float64
Study Satisfaction	Satisfacción con sus estudios	0 a 5 0: Poco o nada 5: Mucho
Job Satisfaction	Satisfacción con su trabajo	0 a 5 0: Poco o nada 5: Mucho
Sleep Duration	Duración del sueño	Less than 5 hours 5-6 hours 7-8 hours More than 8 hours
Dietary Habits	Hábitos alimenticios	Unhealthy Moderate Healthy




Fig. 4 Conteo de valores en la columna "Job Satisfaction"

La columna de "Work/Study Hours" generaliza ambos tipos de respuesta por lo que se puede conservar, si estuvieran separados se borraría la relacionada al trabajo.




Fig. 4 Conteo de valores en la columna "Work/Study Hours"

3) Datos tipo "str"

Para las columnas de "City" y "Degree" se hizo profundizo un poco más sobre que representaban estos datos y si convenía mantenerlos y de que forma. Se realizó la siguiente grafica para poder tener una representación visual de cómo se comportan los datos.




Fig. 5 Distribución de ciudades según depresión




Fig. 6 Distribución de carreras según depresión

Como se puede ver en la gráfica de las carreras la gran cantidad de los datos se encuentran en el valor "Class 12" esto nos indica no realmente que si se encuentra en la clase 12 tiende a tener más probabilidades de presentar depresión, si no, como fueron recabados los datos. Recordemos que la gran mayoría son estudiantes por lo que pocos han de tener un rango académico mayor a estudiante, como se puede ver en la gráfica. Por lo que estos datos nos indican como fue tomada la muestra no un indicador real.

Algo similar sucede con las ciudades, esos datos representan las regiones geográficas donde se recopilaron los datos no indican que al provenir o residir en cierta ciudad es más probable de padecer depresión. Es por eso que se tomó la decisión de eliminar ambas columnas, también para lograr que el modelo pudiera hacer el análisis enfocándose en la forma de vida más que en el lugar que se reside.

4) Datos extremos

Finalmente se identifico que la distribución de datos en la columna de tenía algunos valores extremos.




Fig. 7 Distribución de edad

Como se puede ver en la caja de bigotes la mayoría de edad esta entre los 21 años y los 30, pero hay registros de hasta 56 años. Para mantener los datos centrados y que se apegue al perfil de un estudiante se decidió mantener los datos en un rango de máximo 30 años.




Fig. 8 Conteo de la columna "Age"

5) Transformación de los datos

Después de hacer el análisis y decidir que columnas se quedarán, se transformaron los datos para poder mantener todo en valores numéricos. Es decir, columnas como "Sleep duration" pasarían de tener valores como "Menos de 5 horas" a un valor numérico como "0". Esto para que al modelo le sea más fácil leer los datos de clasificación.

```

===== Info del Dataset =====
<class 'pandas.DataFrame'>
Index: 21802 entries, 1 to 27900
Data columns (total 12 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Gender                                21802 non-null  int64
1   Age                                   21802 non-null  float64
2   Academic Pressure                     21802 non-null  float64
3   CGPA                                  21802 non-null  float64
4   Study Satisfaction                    21802 non-null  float64
5   Sleep Duration                        21790 non-null  float64
6   Dietary Habits                        21793 non-null  float64
7   Suicidal Thoughts                    21802 non-null  int64
8   Work/Study Hours                     21802 non-null  float64
9   Financial Stress                      21800 non-null  float64
10  Family Illness                        21802 non-null  int64
11  Depression                            21802 non-null  int64
dtypes: float64(8), int64(4)

```

Fig. 9 Columnas del set de datos transformados

Al hacer la transformación hay datos que se clasificaban como otros, al ser muy pocos en todos los datos se decidieron eliminarlos.

```

===== Datos faltantes =====
Null data:
Gender                                0
Age                                   0
Academic Pressure                     0
CGPA                                  0
Study Satisfaction                    0
Sleep Duration                        12
Dietary Habits                        9
Suicidal Thoughts                    0
Work/Study Hours                     0
Financial Stress                      2
Family Illness                        0
Depression                            0
dtype: int64
Null data: 23
/=/=/=/=/=/=/=/=/=/=

```

Fig. 10 Datos otros transformados en "null data"

Finalmente, el set de datos tras ser analizado y limpiado queda con 21,779 en 11 columnas de atributos y 1 columna que funciona como el objetivo a predecir.

III. PRIMER MODELO DE PREDICCIÓN

1) Presentación del modelo

Tras el extenso análisis de los datos y su limpieza es momento de elegir un modelo de predicción para resolver este enigma. Por la naturaleza de los datos a primera instancia se hace notar que el valor que intentamos predecir es 1 o 0, es decir, categórico por lo que el modelo que mejor se ajusta a estas situaciones es la regresión logística.

Este modelo consiste en aprovechar el modelo lineal y aplicar la función de la sigmoide, la cual hace que el resultado entre en un rango de 1 y 0, justo lo que necesitamos para este problema. La ecuación de la sigmoide es la siguiente.

$$f(x) = \frac{1}{1 - e^{-x}}$$

Fig. 11 Ecuación de la sigmoide

De esta manera se pueden lograr 2 cosas, primero como ya se mencionó el resultado entra en un rango de 1 a 0, el segundo es que la grafica toma una forma distinta que se ajusta a los datos de una mejor forma.






Fig. 12 Función de regresión logística



A diferencia de la regresión lineal en la que en ocasiones algunos datos eran registrados de forma incorrecta por la manera que los captaba arriba o debajo de la línea, la regresión logística permite establecer un umbral para determinar a que categoría pertenece cada dato de manera más eficiente. De esta forma, el modelo puede separar las observaciones en las clases correspondientes y realizar predicciones más adecuadas para la naturaleza binaria de nuestro problema.

2) Optimización





Modelo 1



Modelo 2 (One hot encoding)



Modelo 3 (Learning rate 3 con One Hot encoding)



Modelo 4 (Learning rate 3)

<https://aws.amazon.com/es/what-is/logistic-regression/>